BÁO CÁO PHÂN TÍCH MÔ HÌNH AI

PHÂN LOẠI BỆNH TRÊN CÂY DÂU TÂY BẰNG MOBILENETV3-LARGE

Sinh viên thực hiện: Nguyễn Tuấn Kiệt – 23139023

Hoàng Gia Phát – 23139033

Đỗ Thanh Sơn – 23139039

Nguyễn Đình Thi – 23139044

TP. Hồ Chí Minh, tháng 10 năm 2026

TÓM TẮT

Đồ án xây dựng mô hình phân loại ảnh bệnh trên cây dâu tây bằng phương pháp học chuyển giao với MobileNetV3-Large. Bài toán gồm tám lớp, trong đó có bảy lớp bệnh và một lớp khỏe mạnh. Dữ liệu được kiểm tra, loại ảnh trùng và chia thành ba tập phục vụ huấn luyện, lựa chọn mô hình và kiểm tra kết quả.

Sau khi xử lý, bộ dữ liệu còn 2.915 ảnh. Mô hình được huấn luyện qua hai giai đoạn: huấn luyện lớp phân loại và tinh chỉnh một phần mạng trích xuất đặc trưng. Trên tập kiểm tra gồm 435 ảnh, mô hình phân loại đúng 425 ảnh, đạt độ chính xác 97,70% và Macro-F1 95,49%. Các trường hợp nhầm lẫn tập trung ở ba lớp bệnh trên quả: mốc xám, thán thư và phấn trắng.

Mô hình được chuyển đổi sang TensorFlow Lite ở hai định dạng FP32 và FP16. Bản FP16 có dung lượng khoảng 6,00 MB, giảm gần một nửa so với FP32. Kết quả cho thấy tiềm năng ứng dụng của mô hình, đồng thời đặt ra yêu cầu đánh giá thêm trên ảnh thực tế và thiết bị đích trước khi triển khai.

Từ khóa: MobileNetV3-Large, bệnh dâu tây, học chuyển giao, phân loại ảnh, TensorFlow Lite.

MỤC LỤC

TÓM TẮT **i**

1 GIỚI THIỆU ĐỀ TÀI **1**
1.1 Đặt vấn đề 1
1.2 Mục tiêu 1
1.3 Phạm vi thực hiện 1

2 CƠ SỞ LÝ THUYẾT **2**
2.1 Phân loại ảnh và mạng nơ-ron tích chập 2
2.2 MobileNetV3-Large và học chuyển giao 2
2.3 Hàm mất mát và tối ưu 2
2.4 Các chỉ số đánh giá 3

3 DỮ LIỆU VÀ PHƯƠNG PHÁP THỰC HIỆN **4**
3.1 Bộ dữ liệu 4
3.2 Làm sạch và tiền xử lý 5
3.3 Tăng cường dữ liệu 5
3.4 Thiết kế mô hình 6
3.5 Quy trình huấn luyện 6

4 KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN **8**
4.1 Môi trường thực nghiệm 8
4.2 Kết quả huấn luyện 8
4.3 Kết quả trên tập kiểm tra 10
4.4 Phân tích ma trận nhầm lẫn 11
4.5 Đường ROC và precision–recall 13
4.6 Chuyển đổi mô hình sang TensorFlow Lite 14

5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN **15**
5.1 Kết luận 15
5.2 Hạn chế 15
5.3 Hướng phát triển 15

TÀI LIỆU THAM KHẢO **16**

CHƯƠNG 1

GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề

Việc nhận biết bệnh qua hình ảnh là một hướng ứng dụng của xử lý ảnh trong nông nghiệp. Với cây dâu tây, dấu hiệu bệnh có thể xuất hiện trên lá, hoa hoặc quả. Một mô hình phân loại ảnh có thể hỗ trợ sàng lọc ban đầu bằng cách gán ảnh đầu vào vào nhóm bệnh đã được học.

Trong đồ án này, MobileNetV3-Large được sử dụng làm mạng trích xuất đặc trưng. Mô hình được khởi tạo bằng trọng số ImageNet và điều chỉnh đầu phân loại cho tám lớp của bộ dữ liệu. Hướng tiếp cận này cho phép tận dụng đặc trưng ảnh đã học, đồng thời giảm yêu cầu huấn luyện toàn bộ mạng từ đầu.

1.2 Mục tiêu

Mô hình tập trung xây dựng quy trình từ chuẩn bị dữ liệu đến đánh giá mô hình. Các mục tiêu cụ thể gồm kiểm tra và chia dữ liệu; huấn luyện MobileNetV3-Large theo hai giai đoạn; đánh giá kết quả tổng thể và từng lớp; phân tích các trường hợp nhầm lẫn; chuyển đổi mô hình sang TensorFlow Lite để chuẩn bị cho bước tích hợp ứng dụng.

1.3 Phạm vi thực hiện

Hệ thống nhận một ảnh RGB và dự đoán một nhãn trong tám lớp. Mô hình chỉ phân loại toàn ảnh, chưa xác định vị trí vùng bệnh hoặc mức độ tổn thương. Kết quả thực nghiệm trong báo cáo được tổng hợp từ lần chạy đã lưu trong notebook của đồ án [1]. Việc kiểm tra ngoài thực địa và đo hiệu năng trên thiết bị di động chưa được thực hiện.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1 Phân loại ảnh và mạng nơ-ron tích chập

Phân loại ảnh là bài toán ánh xạ ảnh đầu vào sang một nhãn thuộc tập lớp xác định trước. Mạng nơ-ron tích chập học các đặc trưng thông qua nhiều lớp xử lý. Những lớp đầu thường biểu diễn các cấu trúc đơn giản; các lớp sâu hơn kết hợp chúng thành biểu diễn phục vụ phân loại.

Với tám lớp đầu ra, mô hình sử dụng hàm softmax để chuyển logits z_k thành các điểm dự đoán:

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^{8} e^{z_j}}, \qquad \hat{y} = \arg\max_k p_k. \tag{2.1}$$

Nhãn có điểm cao nhất được chọn làm kết quả. Điểm softmax thể hiện mức ưu tiên tương đối giữa các lớp trong mô hình, chưa được hiệu chuẩn thành độ tin cậy chẩn đoán.

2.2 MobileNetV3-Large và học chuyển giao

Đồ án sử dụng MobileNetV3-Large có sẵn trong Keras, với trọng số khởi tạo từ ImageNet. Phần phân loại ban đầu được loại bỏ và thay bằng đầu phân loại mới phù hợp với dữ liệu dâu tây. Kiến trúc nội bộ của mạng được giữ nguyên.

Học chuyển giao được thực hiện bằng cách giữ cố định mạng nền trong giai đoạn đầu để huấn luyện đầu phân loại. Khi đầu phân loại đã thích nghi với nhãn mới, một phần các lớp cuối của mạng nền được mở để tinh chỉnh bằng tốc độ học nhỏ hơn. Cách huấn luyện này giúp điều chỉnh đặc trưng theo bộ dữ liệu đích mà không thay đổi quá mạnh các trọng số đã học.

2.3 Hàm mất mát và tối ưu

Mô hình dùng sparse categorical cross-entropy. Với một ảnh có nhãn thật y, hàm mất mát cơ bản được xác định bởi:

$$\mathcal{L}_{\mathrm{CE}} = -\log p_y. \tag{2.2}$$

Để giảm ảnh hưởng của mất cân bằng dữ liệu, mẫu thuộc lớp c được gán trọng số:

$$w_c = \frac{N_{\text{train}}}{K n_c}, \tag{2.3}$$

trong đó $K = 8$, N_{train} là tổng số ảnh huấn luyện và n_c là số ảnh huấn luyện của lớp c. Những lớp ít mẫu có trọng số lớn hơn. Bộ tối ưu Adam được sử dụng để cập nhật các trọng số được phép huấn luyện.

2.4 Các chỉ số đánh giá

Ngoài độ chính xác tổng thể, đồ án sử dụng Precision, Recall và F1-score để đánh giá từng lớp:

$$\text{Accuracy} = \frac{\text{Số ảnh dự đoán đúng}}{\text{Tổng số ảnh kiểm tra}}, \tag{2.4}$$

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \tag{2.5}$$

$$F1_c = \frac{2P_c R_c}{P_c + R_c}. \tag{2.6}$$

Ở đây, TP_c là số mẫu lớp c được nhận đúng; FP_c là số mẫu lớp khác bị gán vào lớp c; FN_c là số mẫu lớp c bị dự đoán sang lớp khác. Macro-F1 là trung bình F1-score của tám lớp, giúp thể hiện rõ hơn kết quả ở các lớp ít mẫu.

CHƯƠNG 3

DỮ LIỆU VÀ PHƯƠNG PHÁP THỰC HIỆN

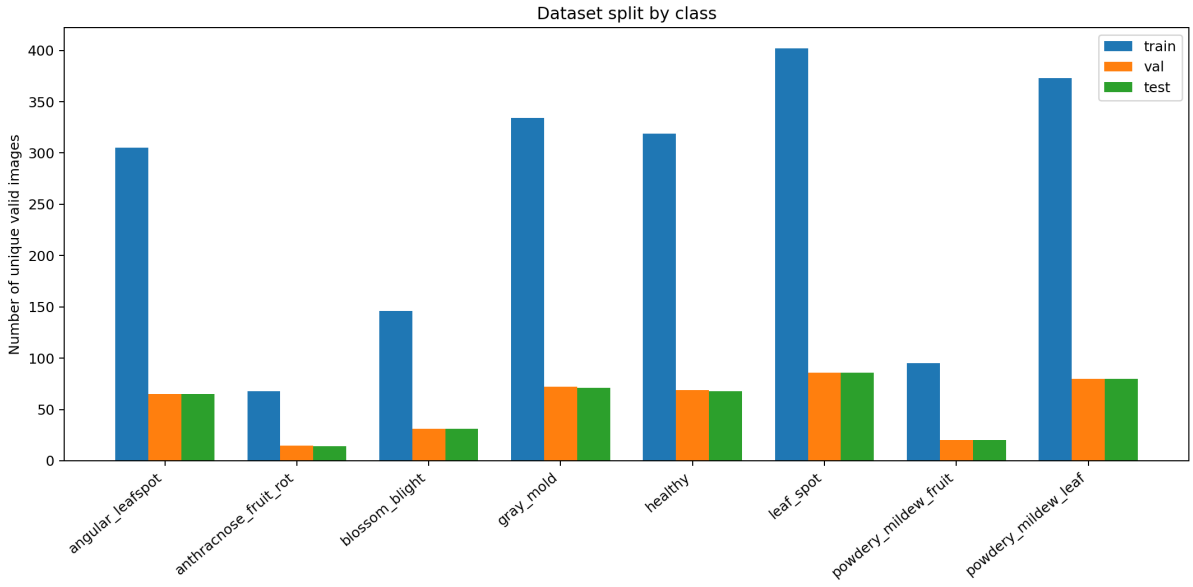
3.1 Bộ dữ liệu

Bộ dữ liệu được tổ chức thành tám thư mục tương ứng với tám nhãn. Ban đầu có 2.956 ảnh. Sau khi kiểm tra và loại 41 ảnh trùng trong lớp đốm lá, số ảnh còn lại là 2.915. Không ghi nhận ảnh lỗi giải mã trong lần xử lý này.

Bảng 3.1: Phân bố dữ liệu sau khi làm sạch.

Lớp	Tổng	Train	Validation	Test
Đốm lá góc cạnh	435	305	65	65
Thán thư trên quả	97	68	15	14
Cháy hoa	208	146	31	31
Mốc xám	477	334	72	71
Khỏe mạnh	456	319	69	68
Đốm lá	574	402	86	86
Phấn trắng trên quả	135	95	20	20
Phấn trắng trên lá	533	373	80	80
Tổng	**2.915**	**2.042**	**438**	**435**

Dữ liệu được chia theo từng lớp với tỷ lệ mục tiêu 70% huấn luyện, 15% validation và 15% kiểm tra; seed được đặt bằng 42. Số lượng giữa các lớp chênh lệch đáng kể: lớp đốm lá có 574 ảnh, trong khi lớp thán thư trên quả chỉ có 97 ảnh.



Hình 3.1: Phân bố ảnh giữa ba tập dữ liệu.

3.2 Làm sạch và tiền xử lý

Ảnh được đọc bằng Pillow, sửa hướng theo thông tin EXIF và chuyển về RGB. Chương trình tính mã băm SHA-256 từ kích thước và giá trị pixel để nhận biết ảnh trùng hoàn toàn. Các ảnh hợp lệ được lưu thành PNG trước khi đưa vào mô hình.

Trong quá trình nạp dữ liệu, ảnh được thay đổi kích thước về 224×224 bằng nội suy bilinear, chuyển sang kiểu float32 và gom thành batch 32 ảnh. Giá trị pixel được giữ trong khoảng $[0, 255]$ vì mô hình đã có bước chuẩn hóa bên trong. Tập huấn luyện được xáo trộn sau mỗi epoch; thứ tự của validation và test được giữ cố định.

3.3 Tăng cường dữ liệu

Các phép biến đổi được áp dụng trực tuyến trên tập huấn luyện gồm lật ngang và dọc, xoay, zoom, thay đổi tương phản và độ sáng. Hệ số xoay, zoom, tương phản và độ sáng được đặt ở mức 0,10 trong cấu hình. Sau biến đổi, giá trị pixel được giới hạn lại trong khoảng $[0, 255]$.

Validation và test không sử dụng tăng cường dữ liệu. Việc chia tập được thực hiện trước augmentation để tránh đưa các biến thể sinh ra từ cùng ảnh vào nhiều tập.

3.4 Thiết kế mô hình

Mạng nhận ảnh kích thước 224×224×3. MobileNetV3-Large được cấu hình với `alpha=1.0`, bỏ đầu phân loại ImageNet và sử dụng Global Average Pooling để tạo vector đặc trưng. Sau đó, vector đi qua Dropout và lớp Dense tám đầu ra.

Bảng 3.2: Các thành phần chính của mô hình.

Thành phần	Cấu hình
Ảnh đầu vào	$224 \times 224 \times 3$, RGB
Mạng nền	MobileNetV3-Large, trọng số ImageNet
Gộp đặc trưng	Global Average Pooling
Dropout	Tỷ lệ 0,30
Lớp phân loại	Dense, 8 nút, softmax
Hàm mất mát	Sparse categorical cross-entropy
Bộ tối ưu	Adam

Dropout được sử dụng khi huấn luyện nhằm hạn chế sự phụ thuộc quá mức vào một số đặc trưng. Khi suy luận, lớp này không loại bỏ đặc trưng.

3.5 Quy trình huấn luyện

3.5.1 Giai đoạn huấn luyện đầu phân loại

Toàn bộ mạng nền được đóng băng, chỉ các tham số của đầu phân loại được cập nhật. Giai đoạn này chạy 10 epoch với tốc độ học khởi đầu 10^{-3}, giúp đầu phân loại học ánh xạ từ đặc trưng ảnh sang tám nhãn của bộ dữ liệu.

3.5.2 Giai đoạn tinh chỉnh

Mô hình bắt đầu từ checkpoint tốt nhất của giai đoạn đầu. Khoảng 30% số layer cuối trong danh sách layer của mạng nền được mở để huấn luyện, ngoại trừ các lớp Batch Normalization. Giai đoạn này chạy 15 epoch với tốc độ học khởi đầu 10^{-5}. Batch Normalization được giữ ở chế độ suy luận trong cả hai giai đoạn.

Bảng 3.3: Thông số huấn luyện.

Thông số	Huấn luyện đầu phân loại	Fine-tune
Số epoch đã chạy	10	15
Tốc độ học khởi đầu	10^{-3}	10^{-5}
Batch size	32	32
Mạng nền	Đóng băng	Mở một phần các lớp cuối
Batch Normalization	Đóng băng	Đóng băng
Tiêu chí lưu checkpoint	Validation loss thấp nhất	Validation loss thấp nhất

ModelCheckpoint được dùng để lưu trọng số tốt nhất. EarlyStopping theo dõi validation loss với patience bằng 5; ReduceLROnPlateau giảm tốc độ học một nửa khi loss không cải thiện trong hai epoch, với giá trị nhỏ nhất 10^{-7}. Trong lần chạy này, cả hai giai đoạn đều hoàn thành số epoch đã cấu hình.

Sau huấn luyện, hai checkpoint tốt nhất được so sánh trên validation. Checkpoint có loss thấp hơn được chọn để đánh giá test. Tập test không được dùng để quyết định checkpoint.

CHƯƠNG 4

KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

4.1 Môi trường thực nghiệm

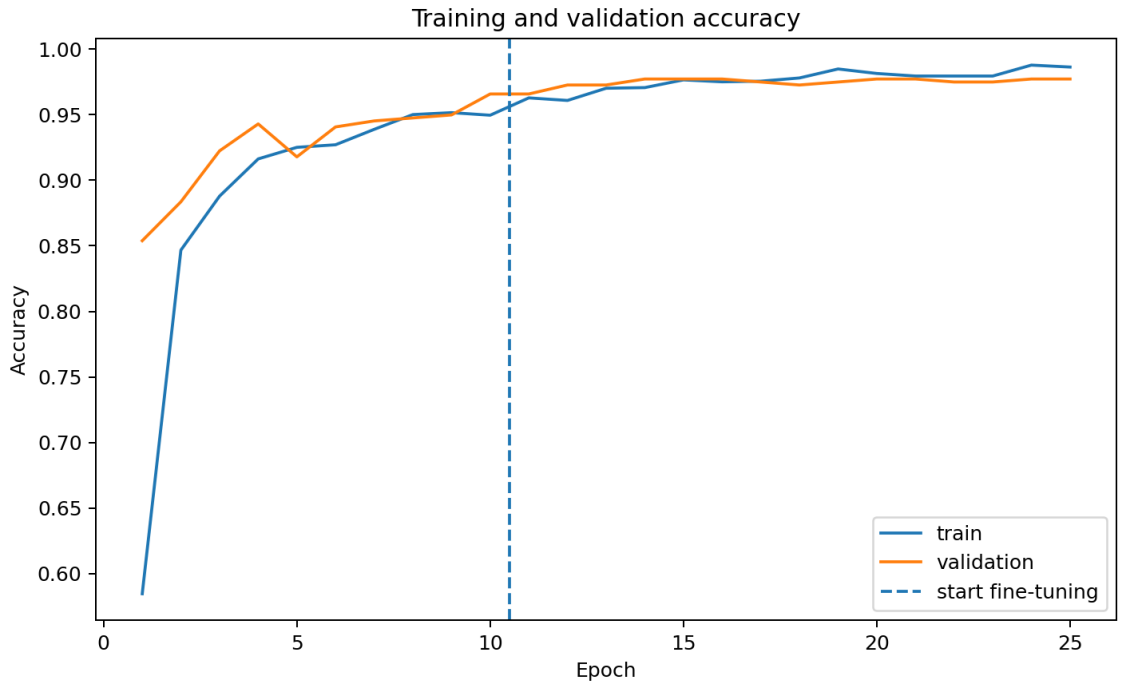
Chương trình được chạy trên Kaggle với Python 3.12.13 và TensorFlow 2.20.0. Môi trường nhận diện hai GPU Tesla T4. Mã huấn luyện không sử dụng chiến lược huấn luyện phân tán, vì vậy số GPU được nhận diện không được dùng để suy ra mức tăng tốc khi chạy.

4.2 Kết quả huấn luyện

Bảng 4.1 trình bày kết quả của checkpoint tốt nhất ở mỗi giai đoạn. Fine-tune giảm validation loss từ 0,118797 xuống 0,070470; đồng thời validation accuracy tăng từ 96,58% lên 97,72%. Do có validation loss thấp hơn, checkpoint fine-tune được chọn làm mô hình cuối cùng.

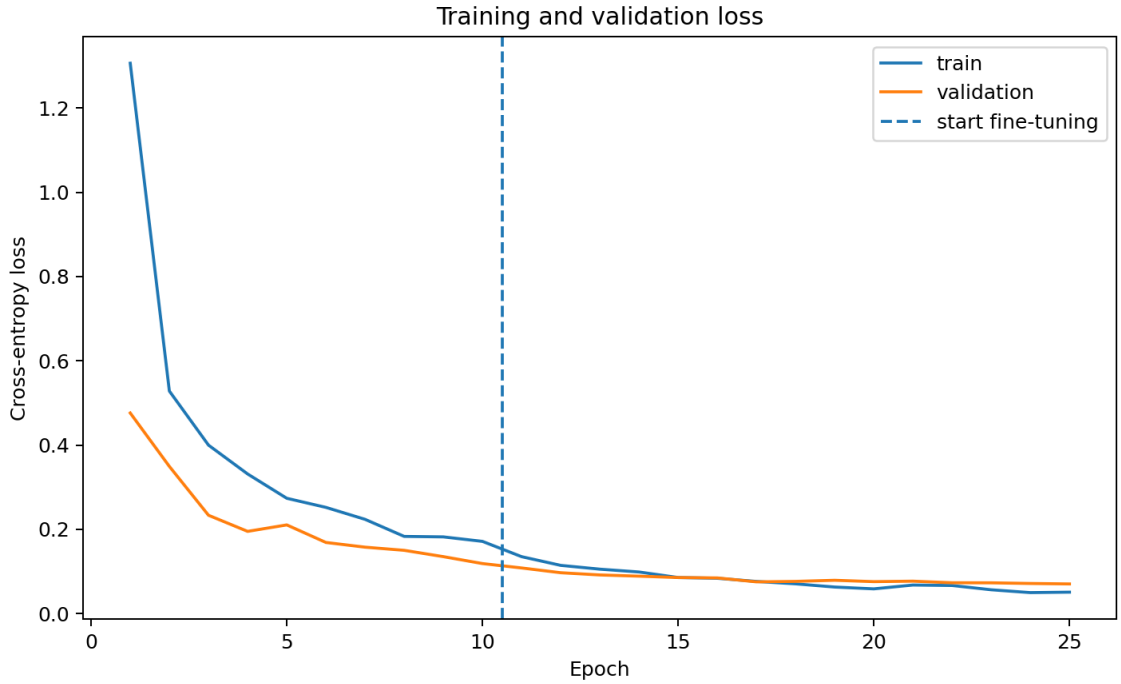
Bảng 4.1: So sánh checkpoint trên tập validation.

Giai đoạn	Validation loss	Validation accuracy
Huấn luyện đầu phân loại	0,118797	96,58%
Fine-tune	**0,070470**	**97,72%**



Hình 4.1: Độ chính xác của mô hình trong quá trình huấn luyện.

Độ chính xác tăng nhanh trong các epoch đầu, sau đó cải thiện chậm hơn. Đường đứt tại epoch 10 đánh dấu thời điểm chuyển sang fine-tune. Ở cuối quá trình, độ chính xác trên train và validation tương đối gần nhau.



Hình 4.2: Giá trị loss trên train và validation.

Loss của cả hai tập giảm dần. Trong giai đoạn cuối, validation loss không có xu

hướng tăng mạnh kéo dài. Kết quả này cho thấy quá trình học ổn định trên phép chia hiện tại. Tuy nhiên, loss train còn chịu tác động của augmentation và trọng số lớp, nên chênh lệch giữa hai đường cần được xem xét cùng các chỉ số đánh giá khác.

4.3 Kết quả trên tập kiểm tra

Mô hình dự đoán đúng 425 trên tổng số 435 ảnh kiểm tra, tương ứng accuracy 97,70%. Macro-F1 đạt 95,49%, thấp hơn weighted-F1 khoảng 2,28 điểm phần trăm. Sự chênh lệch này phản ánh việc kết quả ở một số lớp ít mẫu còn thấp hơn các lớp còn lại.

Bảng 4.2: Các chỉ số đánh giá trên tập kiểm tra.

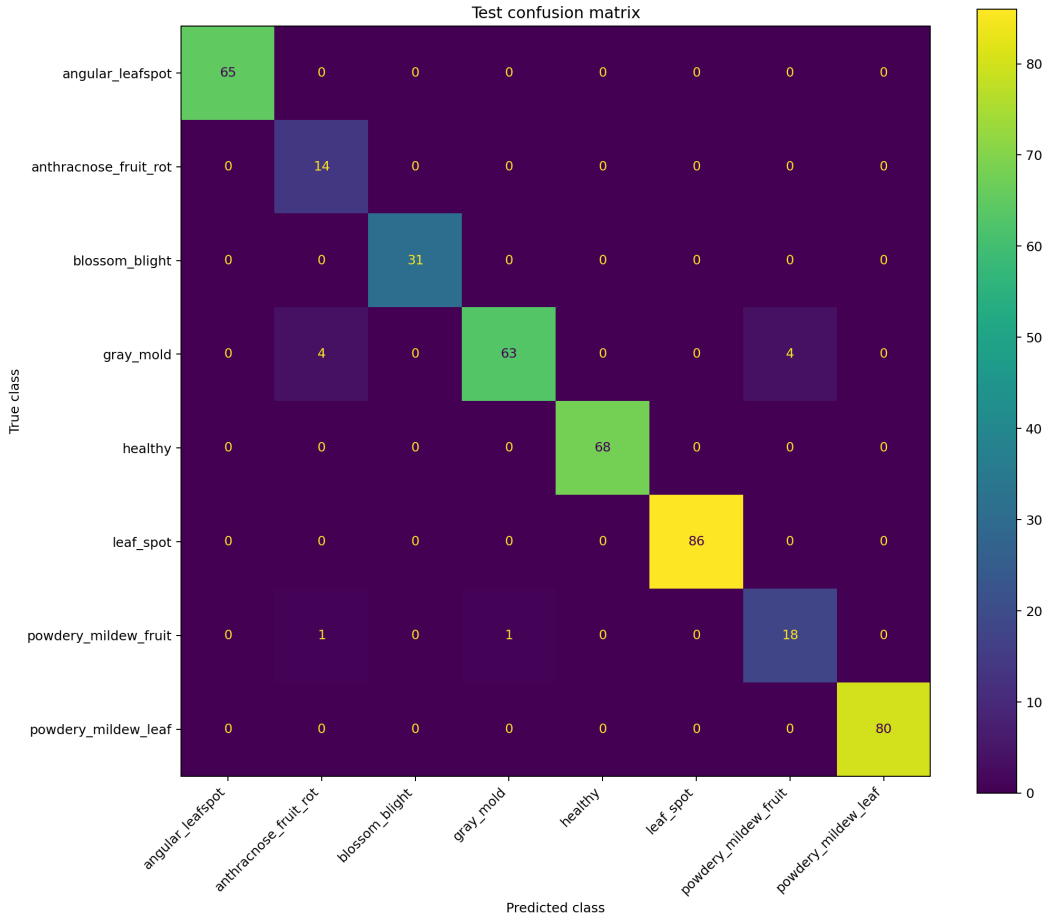
Chỉ số	Kết quả
Accuracy	97,70%
Balanced accuracy	97,34%
Macro precision	94,24%
Macro recall	97,34%
Macro-F1	95,49%
Weighted-F1	97,77%
MCC	0,9731
Macro ROC-AUC (OvR)	0,9995
Macro average precision (OvR)	0,9928

Bảng 4.3: Kết quả phân loại theo từng lớp.

Lớp	Precision	Recall	F1-score	Số ảnh
Đốm lá góc cạnh	1,0000	1,0000	1,0000	65
Thán thư trên quả	0,7368	1,0000	0,8485	14
Cháy hoa	1,0000	1,0000	1,0000	31
Mốc xám	0,9844	0,8873	0,9333	71
Khỏe mạnh	1,0000	1,0000	1,0000	68
Đốm lá	1,0000	1,0000	1,0000	86
Phấn trắng trên quả	0,8182	0,9000	0,8571	20
Phấn trắng trên lá	1,0000	1,0000	1,0000	80

Năm lớp được phân loại đúng toàn bộ trong tập kiểm tra này. Hai lớp có F1-score thấp nhất là thán thư trên quả và phấn trắng trên quả, lần lượt đạt 0,8485 và 0,8571. Số ảnh kiểm tra của hai lớp này chỉ là 14 và 20, nên một số ít dự đoán sai cũng làm chỉ số thay đổi đáng kể.

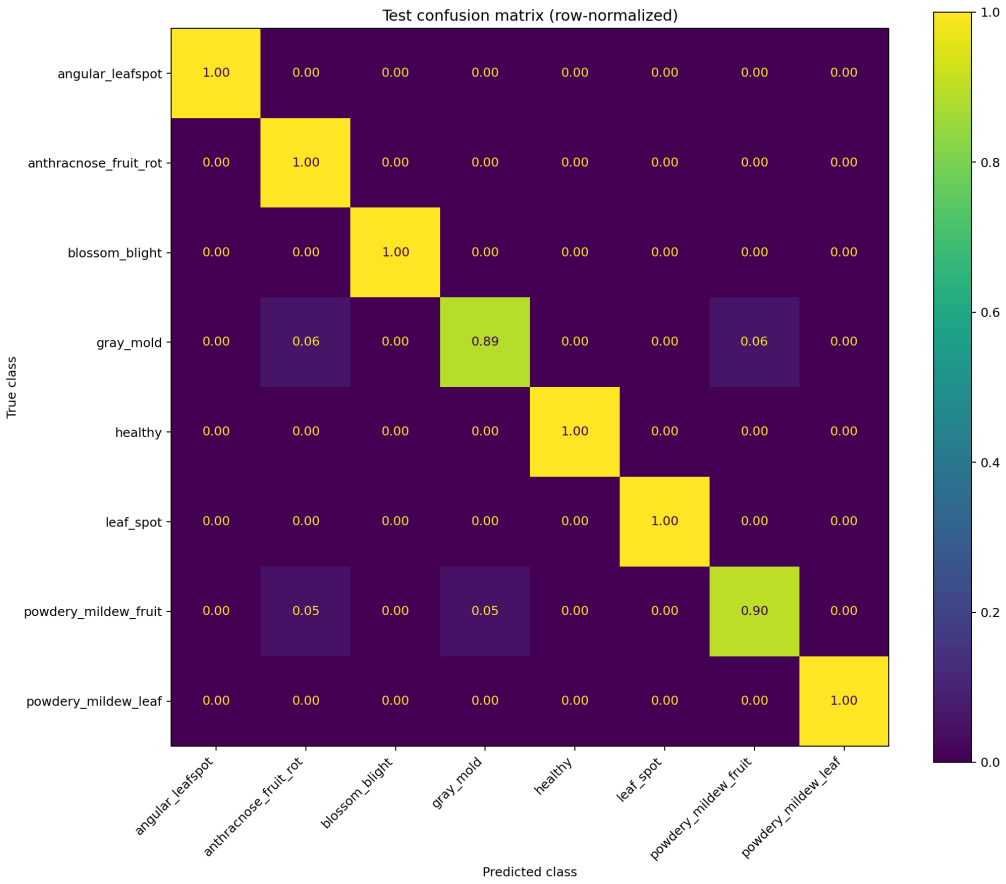
4.4 Phân tích ma trận nhầm lẫn



Hình 4.3: Ma trận nhầm lẫn trên tập kiểm tra.

Trong ma trận nhầm lẫn, hàng biểu diễn nhãn thật và cột biểu diễn nhãn dự đoán. Cả 10 trường hợp sai đều nằm trong ba lớp bệnh trên quả. Cụ thể, tám ảnh mốc xám bị nhận nhầm, gồm bốn ảnh sang thán thư và bốn ảnh sang phấn trắng. Hai ảnh phấn trắng bị gán lần lượt sang thán thư và mốc xám.

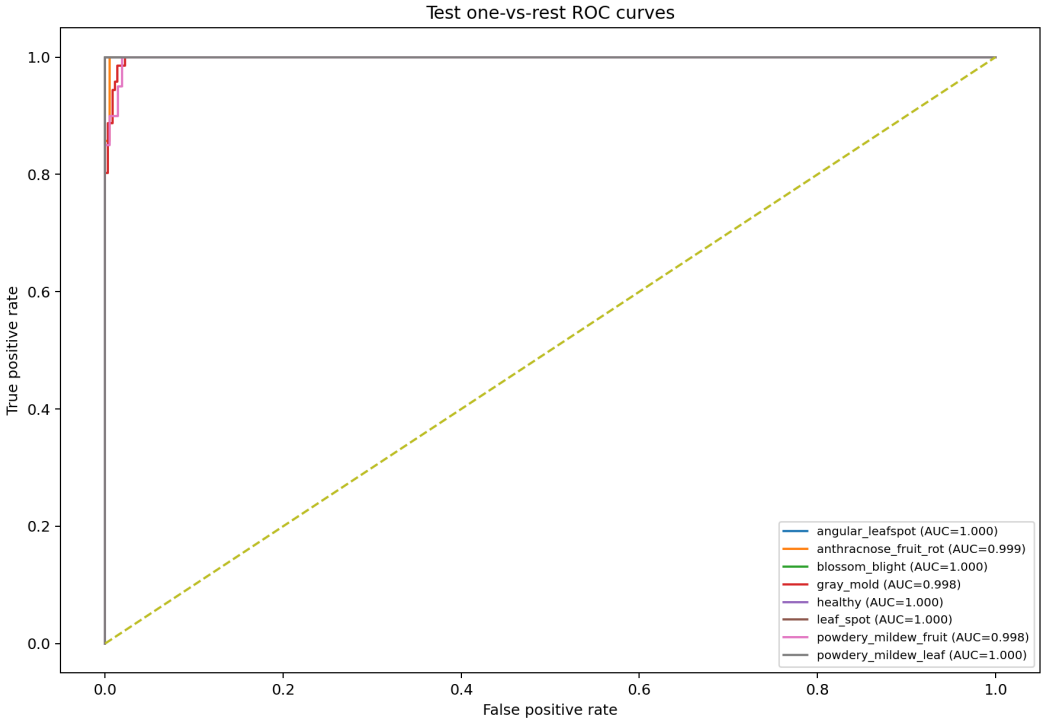
Lớp thán thư có recall bằng 100% vì cả 14 ảnh thật đều được nhận đúng. Tuy nhiên, mô hình còn gán thêm năm ảnh lớp khác vào nhãn này, làm precision giảm còn 73,68%. Với lớp mốc xám, precision cao nhưng recall thấp hơn: mô hình nhận đúng 63/71 ảnh thật, tương ứng recall 88,73%.



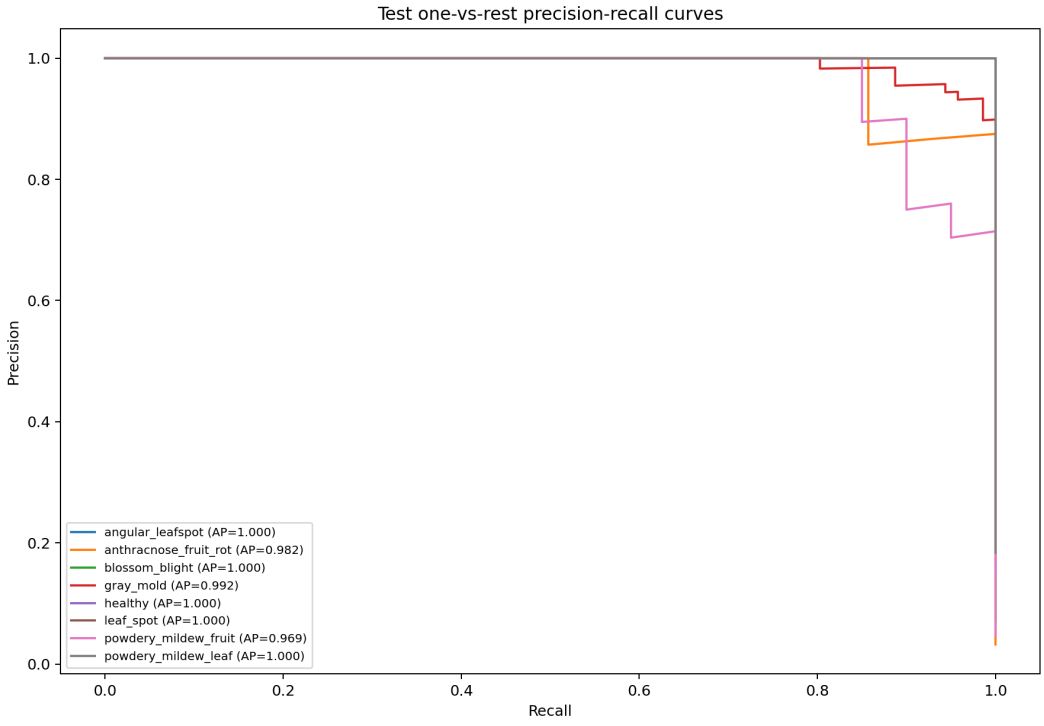
Hình 4.4: Ma trận nhầm lẫn chuẩn hóa theo nhãn thật.

Các biểu hiện trên bề mặt quả, điều kiện ánh sáng hoặc nền ảnh có thể là những yếu tố gây nhầm lẫn. Để xác định nguyên nhân, cần đối chiếu trực tiếp các ảnh bị dự đoán sai và kiểm tra lại nhãn. Kết quả hiện tại mới cho thấy nhóm lớp cần ưu tiên cải thiện, chưa đủ để kết luận nguyên nhân cụ thể.

4.5 Đường ROC và precision–recall



Hình 4.5: Đường ROC theo phương pháp one-vs-rest.



Hình 4.6: Đường precision–recall theo phương pháp one-vs-rest.

Macro ROC-AUC đạt 0,9995 và macro average precision đạt 0,9928. Các chỉ số này thể hiện khả năng phân biệt lớp qua nhiều ngưỡng. Chúng không đồng nhất với accuracy hoặc precision tại nhãn được chọn bằng argmax. Vì vậy, AUC cao vẫn có thể xuất hiện cùng precision thấp hơn ở lớp thán thư trên quả.

4.6 Chuyển đổi mô hình sang TensorFlow Lite

Mô hình được chuyển sang TFLite ở định dạng FP32 và FP16. Hai phép chuyển đổi đều hoàn tất. Dung lượng FP32 là 11,924 MB, trong khi FP16 là 6,004 MB, giảm khoảng 49,65%.

Bảng 4.4: Kết quả chuyển đổi TensorFlow Lite.

Thuộc tính	FP32	FP16
Dung lượng	11,924 MB	6,004 MB
Kiểu dữ liệu đầu vào	float32	float32
Dải giá trị pixel	$[0, 255]$	$[0, 255]$
Trạng thái chuyển đổi	Thành công	Thành công

Khi tích hợp vào ứng dụng, ảnh cần được chuyển RGB, thay đổi kích thước về 224×224 và giữ đúng dải giá trị đầu vào. Thứ tự nhãn phải khớp với thứ tự đầu ra của mô hình. Bản TFLite chưa được đánh giá lại trên tập test hoặc đo độ trễ trên thiết bị, nên kết quả độ chính xác trong báo cáo vẫn là kết quả của mô hình Keras.

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đồ án đã xây dựng quy trình phân loại tám lớp ảnh bệnh và khỏe mạnh trên cây dâu tây bằng MobileNetV3-Large. Quy trình bao gồm làm sạch dữ liệu, tăng cường ảnh huấn luyện, học chuyển giao, fine-tune và đánh giá trên tập kiểm tra riêng.

Mô hình cuối cùng đạt accuracy 97,70% và Macro-F1 95,49% trên 435 ảnh kiểm tra. Fine-tune cải thiện kết quả validation so với giai đoạn chỉ huấn luyện đầu phân loại. Phân tích lỗi cho thấy mốc xám, thán thư trên quả và phấn trắng trên quả là ba nhóm cần tiếp tục cải thiện. Việc chuyển đổi sang TFLite FP16 giảm dung lượng mô hình xuống khoảng 6 MB, tạo cơ sở cho bước thử nghiệm tích hợp ứng dụng.

5.2 Hạn chế

Kết quả được đánh giá trên một phép chia dữ liệu và một seed. Dữ liệu chưa được chia theo cây, vườn hoặc phiên chụp; kiểm tra trùng pixel chỉ loại được bản sao hoàn toàn. Vì vậy, ảnh có liên quan về nguồn vẫn có khả năng xuất hiện ở các tập khác nhau.

Số mẫu của các lớp chưa cân bằng, đặc biệt ở thán thư và phấn trắng trên quả. Mô hình cũng chưa có cơ chế nhận biết ảnh ngoài tám lớp, chưa đánh giá trên ảnh chụp mới ngoài thực địa và chưa đo hiệu năng của bản TFLite trên thiết bị đích.

5.3 Hướng phát triển

Trong bước tiếp theo, cần bổ sung ảnh độc lập từ nhiều điều kiện chụp và ưu tiên các lớp đang có ít mẫu. Dữ liệu nên kèm thông tin nguồn để chia tập theo cây hoặc phiên chụp, từ đó đánh giá sát hơn khả năng khái quát hóa.

Bên cạnh việc kiểm tra lại các ảnh nhầm lẫn, có thể thực hiện nhiều lần huấn luyện với seed khác nhau để khảo sát độ ổn định. Trước khi đưa vào ứng dụng, cần đối chiếu đầu ra giữa Keras và TFLite, đánh giá lại độ chính xác và đo thời gian suy luận, bộ nhớ trên thiết bị thực tế.

TÀI LIỆU THAM KHẢO

[1] Notebook thực nghiệm của đồ án, *MobileNetV3-Large — phân loại 8 lớp bệnh/khỏe mạnh trên cây dâu*, tệp `notebookad3086b4fa (1)(1).ipynb`, mã nguồn và kết quả thực nghiệm đã lưu.